# V - Estimation

## I - Définitions

#### Définition 1 - Échantillon

Soit n un entier naturel non nul et X une variable aléatoire. Un n-échantillon de X est un n-uplet  $(X_1,\ldots,X_n)$  tel que les variables aléatoires  $X_1,\ldots,X_n$  soient mutuellement indépendantes et de même loi que X.

#### Définition 2 - Estimateur

Soit X une variable aléatoire suivant une loi de probabilité dépendant d'un paramètre  $\theta$  et  $(X_1, \ldots, X_n)$  un n-échantillon de X. Un estimateur de  $\theta$  est une variable aléatoire  $\varphi(X_1, \ldots, X_n)$  où  $\varphi$  est une application de  $\mathbb{R}^n$  dans  $\mathbb{R}$ .

# Exemple 1 - Estimateurs

• Soit  $(X_1, \ldots, X_n)$  un *n*-échantillon d'une variable aléatoire X. Les quantités suivantes sont des estimateurs de  $\mathbf{E}[X]$ :

$$\star T_1 = \frac{1}{n} \sum_{k=1}^n X_k. \star T_2 = \frac{1}{n-1} \sum_{k=1}^n X_k. \star T_2 = \frac{1}{n-1} \sum_{k=1}^n X_k.$$

- Si  $X \hookrightarrow \mathcal{B}(p)$ , on peut chercher à estimer son paramètre p (qui est égal à son espérance), sa variance  $\sigma^2 = p(1-p), \dots$
- Si  $X \hookrightarrow \mathscr{P}(\lambda)$ , on peut chercher à estimer son paramètre  $\lambda$  (qui est égal à son espérance), la quantité  $\mathbf{P}([X=0]) = \mathrm{e}^{-\lambda}, \dots$
- Si  $X \hookrightarrow \mathcal{U}(\llbracket 1, n \rrbracket)$ , on peut chercher à estimer son paramètre n. Par exemple, si on a accès aux résultats d'un dé, on peut chercher à estimer son nombre de faces.

# Définition 3 - Biais

Soit T un estimateur de  $\theta$ . Le biais de T est le réel  $b_{\theta}(T) = \mathbf{E}[T] - \theta$ . Si  $b_{\theta}(T) = 0$ , l'estimateur T est un estimateur sans biais de  $\theta$ .

#### Exemple 2 - Calculs de biais

Reprenons l'exemple précédent en notant  $m = \mathbf{E}[X]$ .

• Soit 
$$T_1 = \frac{1}{n} \sum_{k=1}^n X_k$$
. Alors,

$$\mathbf{E}[T_1] - m = \frac{1}{n} \sum_{k=1}^{n} \mathbf{E}[X_k] - m = \frac{nm}{n} - m = 0.$$

Ainsi,  $T_1$  est un estimateur sans biais de m.

• Soit 
$$T_2 = \frac{1}{n-1} \sum_{k=1}^n X_k$$
. Alors,

$$\mathbf{E}[T_2] - m = \frac{1}{n-1} \sum_{k=1}^{n} \mathbf{E}[X_k] - m = \frac{nm}{n-1} - m = \frac{m}{n(n-1)}.$$

Ainsi,  $T_2$  est un estimateur de m de biais  $\frac{m}{n(n-1)}$ .

• Soit  $T_3 = \frac{X_1 + X_2}{2}$ . Alors,

$$\mathbf{E}[T_3] - m = \frac{\mathbf{E}[X_1] + \mathbf{E}[X_2]}{2} - m = 0.$$

Ainsi,  $T_3$  est un estimateur sans biais de m.

• Soit  $T_4 = \frac{X_1 X_2}{2}$ . Les variables aléatoires étant indépendantes,

$$\mathbf{E}[T_4] - m = \frac{\mathbf{E}[X_1]\mathbf{E}[X_2]}{2} - m = \frac{m^2}{2} - m = \frac{m(m-2)}{2}.$$

Ainsi,  $T_4$  est un estimateur de m de biais  $\frac{m(m-2)}{2}$ .

Chapitre V - Estimation D 2

#### Définition 4 - Risque quadratique

Soit T un estimateur de  $\theta$ . Le risque quadratique de T est défini par

$$R_{\theta}(T) = \mathbf{E}\left[ (T - \theta)^2 \right].$$

En particulier,

$$R_{\theta}(T) = b(T, \theta)^2 + \mathbf{V}(T)$$

Si T est un estimateur sans biais de  $\theta$ , alors  $R_{\theta}(T) = \mathbf{V}(T)$ .

#### Exemple 3 - Calculs de risques quadratiques

Reprenons les exemples précédents, pour les estimateurs sans biais. On suppose que X admet une variance.

• Comme  $T_1$  est un estimateur sans biais de m, alors les variables aléatoires étant indépendantes,

$$R_m(T_1) = \mathbf{V}(T_1) = \mathbf{V}\left(\frac{1}{n}\sum_{k=1}^n X_k\right) = \frac{1}{n^2}\sum_{k=1}^n \mathbf{V}(X_k)$$
$$= \frac{\mathbf{V}(X)}{n}.$$

• Comme  $T_3$  est sans biais et  $X_1$  et  $X_2$  sont indépendantes,

$$R_m(T_3) = \mathbf{V}(T_3) = \frac{\mathbf{V}(X_1) + \mathbf{V}(X_2)}{4} = \frac{\mathbf{V}(X)}{2}.$$

#### Définition 5 - Meilleur estimateur

L'estimateur  $T_1$  est un meilleur estimateur que  $T_2$  si

$$\forall \theta \in I, R_{\theta}(T_1) \leqslant R_{\theta}(T_2).$$

# Exemple 4 - Comparaison d'estimateurs

En reprenant l'exemple précédent,  $T_1$  est un meilleur estimateur que  $T_3$  dès que  $n \ge 2$ .

# II - Estimation d'une proportion

## Théorème 1 - Loi faible des grands nombres

Soit X une variable aléatoire admettant une moyenne m et une variance  $\sigma^2$ . Soit  $(X_i)_{i\in\mathbb{N}}$  une suite de variables aléatoires indépendantes et de même loi que X. Alors,

$$\forall \ \varepsilon > 0, \ \lim_{n \to +\infty} \mathbf{P} \left( \left| \frac{1}{n} \sum_{k=1}^{n} X_k - m \right| \geqslant \varepsilon \right) = 0.$$

# Définition 6 - Estimateur convergent

Soit  $T_n$  un estimateur de  $\theta$ . L'estimateur  $T_n$  est convergent si pour tout  $\varepsilon > 0$ ,  $\lim_{n \to +\infty} \mathbf{P}(|T_n - \theta| \ge \varepsilon) = 0$ .

# Théorème 2 - Estimation ponctuelle d'une proportion

Soit X une variable aléatoire qui suit une loi de Bernoulli de paramètre p. Soit  $(X_1, \ldots, X_n)$  un n-échantillon de X et  $\overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ . Alors,  $\overline{X}_n$  est un estimateur sans biais et convergent de p.

# Exemple 5 - Sondage

On souhaite connaître la proportion de français favorables à une réforme donnée. On modélise le problème en considérant une variable aléatoire X suivant une loi de Bernoulli de paramètre p. On interroge n français choisis indépendamment dans la population. On note  $X_i$  la réponse donnée par l'individu numéro i:1 si l'individu est favorable et 0 sinon. On suppose que  $X_i$  suit la même loi que X. Pour estimer p, on va donc utiliser la quantité  $\frac{X_1+\cdots+X_n}{n}$ .